

MiroFish: Simulación Social Generativa y Evaluación de Sistemas Multi-Agente en Escenarios Complejos

Andrés Bravo, Joaquín Cadeiras, Bruno De Cruz,
Lucas Ercolano, Eliana Ostrovsky

Universidad de San Andrés

Procesamiento del Lenguaje Natural

Resumen

Los sistemas de simulación social generativa, como MiroFish, pronostican eventos haciendo deliberar a poblaciones de agentes basados en modelos de lenguaje, pero típicamente ejecutan a todos los agentes sobre un mismo modelo. Proponemos poblar la simulación con modelos heterogéneos (Llama-3.3-70B, Gemma-3-27B y Qwen3-8B) bajo la hipótesis de que ello reduciría el sesgo y el costo. Como no existía un punto de comparación, construimos un *benchmark* de tres casos —económico, político y deportivo— con control de fugas de información, y evaluamos los modelos aislados frente a la red heterogénea bajo los mismos regímenes de estrés. Encontramos que, para el pronóstico puro, un modelo aislado y calibrado es más preciso y más barato, mientras que la red heterogénea, sin estímulos externos, colapsa en una ausencia total de predicción; el ahorro de costo real provino de una deduplicación semántica del grafo de conocimiento. La heterogeneidad no autoregula el sesgo, pero sí lo vuelve permeable a inyecciones exógenas, aunque persuasión no equivale a acierto. Concluimos que el valor de la red multi-modelo no está en el *forecasting* sino como laboratorio para estudiar dinámicas socio-técnicas de persuasión y desinformación.

1. Introducción

Los grandes modelos de lenguaje (LLM) hicieron viable simular poblaciones de agentes que conversan, se influyen y toman decisiones, abriendo la puerta a emplear estas simulaciones como instrumento de pronóstico de eventos reales (Park et al., 2023; Yang et al., 2024). MiroFish (MiroFish Contributors, 2025) es un sistema de esta familia: a partir de un corpus semilla instancia una población de agentes en un foro social, los hace deliberar y destila un pronóstico a partir del consenso emergente. La premisa es que, en eventos cuyo desenlace depende de la reacción colectiva, la dinámica social simulada aporta señal más allá de la extrapolación puramente estadística.

Ahora bien, estos entornos suelen ejecutar a todos los agentes sobre un mismo LLM. Una población algorítmicamente homogénea tiende a reproducir las patologías de su único modelo subyacente —cámaras de eco, rigidez de pre-entrenamiento, baja diversidad léxica— y, cuando ese modelo es grande, el costo de cómputo de una simulación completa se vuelve considerable. Postulamos que poblar la simulación con modelos heterogéneos —de distinto tamaño, corpus de pre-entrenamiento y alineación— podría mitigar ambos problemas: la fricción entre arquitecturas divergentes reduciría el sesgo, y la incorporación de modelos más pequeños abarataría la inferencia.

Contrastar esta hipótesis exigía un punto de comparación inexistente: MiroFish no contaba con un *benchmark* que permitiera medir si una modificación mejora o degrada el sistema. Por eso construimos uno propio, con tres casos de distinta temática (económico, político y deportivo) bajo un protocolo estricto de control de fugas de información, y evaluamos primero los modelos en aislamiento (*baseline*) y luego la red multi-modelo, replicando en ambos los mismos regímenes de estrés.

Este trabajo aporta: (i) un mecanismo de ruteo heterogéneo de modelos por agente, con telemetría de costo por llamada; (ii) una deduplicación semántica del grafo de conocimiento que reduce el cómputo sin perder información; (iii) un *benchmark* reproducible de tres casos con *ground truth* aislado; y (iv) un análisis empírico, a lo largo de varias líneas experimentales, de cómo distintas variables afectan la simulación y de en qué difiere el comportamiento de una población homogénea frente a una heterogénea.

2. Trabajo Relacionado

Simulación social generativa. La idea de instanciar agentes basados en LLM que interactúan de forma creíble fue popularizada por los *generati-*

ve agents de Park et al. (2023), y llevada a escala poblacional por OASIS (Yang et al., 2024), que simula hasta un millón de usuarios sobre clones de Twitter y Reddit. MiroFish (MiroFish Contributors, 2025) reutiliza este tipo de entorno pero lo orienta al pronóstico de eventos. A diferencia de estos trabajos, que instancian una población homogénea sobre un único modelo, nuestro foco es la heterogeneidad de modelos dentro de una misma simulación y su efecto sobre el sesgo, el costo y la calidad predictiva.

Degeneración y diversidad. La degradación de sistemas generativos realimentados con su propia salida (*model collapse*) fue caracterizada por Shumailov et al. (2024); observamos un fenómeno análogo cuando la red delibera en circuito cerrado sin entropía exógena. Para cuantificar la variedad lingüística de cada modelo —de forma independiente de su puntería predictiva— empleamos métricas estándar de diversidad: *distinct- n* (Li et al., 2016), Self-BLEU (Zhu et al., 2018) y Vendi Score (Friedman and Dieng, 2023). Por último, dado que las asimetrías de comportamiento entre modelos (proactividad, permeabilidad, cortesía evasiva) se originan en parte en sus esquemas de alineación (Ouyang et al., 2022), también interpretamos las dinámicas inter-modelo a esa luz.

3. Metodología

3.1. Arquitectura del sistema

MiroFish (MiroFish Contributors, 2025) es un motor de predicción que estima el desenlace de un evento simulando la conversación de una población de agentes en un foro social. A partir de un corpus semilla (noticias, informes, encuestas) el sistema construye un grafo de conocimiento, instancia agentes con perfiles y memoria propios, y los hace interactuar durante un número configurable de rondas; el consenso emergente se destila luego en una predicción. La capa de interacción social reutiliza el entorno OASIS (Yang et al., 2024), que clona plataformas tipo Twitter y Reddit e incorpora sistemas de recomendación y un repertorio de acciones (publicar, comentar, seguir, repostear, entre otras).

Sobre esta base introducimos las dos modificaciones que constituyen el aporte técnico de este trabajo:

Ruteo heterogéneo de modelos. Por defecto, todos los agentes de una simulación corren so-

bre un mismo LLM. Implementamos un enrutador (`model_router.py`) que asigna modelos distintos a distintos agentes mediante un mapa declarativo en YAML, junto con una capa de telemetría por llamada (`llm_telemetry.py`) que registra tokens, latencia y costo de cada acción. Esto permite poblar un mismo foro con arquitecturas de pre-entrenamiento y alineación divergentes, y atribuir el costo de cómputo a cada modelo.

Deduplicación semántica del grafo. Durante la ingesta observamos la generación de nodos redundantes o casi idénticos que aumentan el costo y el tiempo de cómputo sin aportar información nueva. Añadimos un paso que fusiona los nodos semánticamente equivalentes antes de insertarlos en el grafo (Neo4j, con `embeddings bge-m3`), reduciendo su tamaño. Su impacto se cuantifica en la Sección 4.

Todas las simulaciones se ejecutan en entornos herméticos: los agentes no acceden a Internet y el corpus semilla respeta un corte temporal estricto anterior al evento, evitando fugas de información (*data leakage*). El resultado real se mantiene aislado del input y solo se emplea en la evaluación.

3.2. Casos de estudio

Al no existir un *benchmark* previo para el sistema, construimos uno propio con tres casos de distinta temática (Tabla 1): económico, político y deportivo. Cada caso plantea un evento cuyo desenlace es posterior al corte documental y verificable de forma objetiva, de modo que el *benchmark* cubre dominios con dinámicas de información heterogéneas manteniendo una evaluación no ambigua. Al representar cada temática con un único evento, el objetivo es la amplitud de dominios y no una medición estadísticamente concluyente dentro de cada uno; una caracterización más fina de las fortalezas y debilidades del sistema por dominio queda como trabajo futuro.

Económico: inflación del IPC (Argentina, 2025).

La variación mensual del Índice de Precios al Consumidor que publica el INDEC. Fijamos el corte documental el 31 de enero de 2025 y pedimos pronosticar el IPC mensual en cuatro horizontes crecientes ($\Delta 1$ a $\Delta 4$: febrero, abril, julio y diciembre de 2025), para evaluar si el sistema captura la trayectoria de desinflación del programa económico entonces vigente. Es el caso más cuantitativo y cerrado: el desenlace es un valor oficial no ambiguo. El *ground truth* muestra una desinflación real pero

Tema	Caso	Predicción	Métrica
Econ.	IPC Arg. 2025	Inflación ($\Delta 1-\Delta 4$)	MAE (%)
Polít.	Bolivia 2025	Ganador / voto	MAE (voto)
Dep.	Copa Am. 2024	Ganador	Acierto

Tabla 1: Los tres casos del *benchmark*: inflación mensual (INDEC), balotaje presidencial (Paz vs. Quiroga) y la final Argentina–Colombia. En todos, el evento es posterior al corte documental y el *ground truth* se mantiene aislado del input.

no lineal —con un rebote a mitad de año— y una inflación acumulada anual en torno al 31.5 %.

Político: balotaje presidencial (Bolivia, 2025).

La segunda vuelta del 19 de octubre de 2025 entre Rodrigo Paz y Jorge “Tuto” Quiroga, en un ciclo marcado por la crisis económica y el colapso electoral del MAS tras casi dos décadas en el poder. A partir de encuestas, resultados de primera vuelta y contexto socioeconómico previos al balotaje, el sistema debe anticipar el ganador y su porcentaje de voto. Es el caso más abierto y polarizado. El resultado real fue el triunfo de Paz con 54.53 % frente al 45.47 % de Quiroga (margen de 9.06 puntos).

Deportivo: final de la Copa América (2024). La final del 14 de julio de 2024 entre Argentina y Colombia, disputada en Miami. Con un corte documental el día previo (13 de julio), el sistema debe predecir el ganador a partir de previas deportivas, estado de forma e historial. Es un caso simple y auto-verificable, de horizonte muy corto (~ 1 día), que opera como prueba de sanidad del protocolo temporal. El desenlace real fue la victoria de Argentina por 1–0 en tiempo suplementario.

3.3. Modelos evaluados

Evaluamos tres LLM de código abierto seleccionados para desacoplar dos variables habitualmente correlacionadas: el tamaño del modelo y la novedad de su fecha de corte. Elegimos deliberadamente una relación invertida entre ambas: Llama-3.3-70B (Llama Team, Meta AI, 2024) es el mayor pero el de corte de conocimiento más antiguo (diciembre de 2023), mientras que Qwen3-8B (Qwen Team, 2025) es el menor y el de corte más reciente (marzo de 2025); Gemma-3-27B (Gemma Team, Google DeepMind, 2025), con corte en agosto de 2024, ocupa una posición intermedia en ambos ejes.¹ Es

¹Qwen no publica una fecha de corte oficial para Qwen3; la estimamos en marzo de 2025 sondeando el modelo con una batería de preguntas sobre eventos datados. Debe tomarse como aproximación, no como dato oficial.

te diseño permite indagar si las patologías que se observen son atribuibles a la escala del modelo o a la cobertura temporal de su pre-entrenamiento.

3.4. Métricas

Distinguimos dos familias. Para el **poder predictivo** (*forecasting*) usamos el Error Absoluto Medio (MAE) respecto del *ground truth*, en la unidad natural de cada caso: puntos porcentuales de inflación (IPC), puntos de voto (Bolivia) y acierto binario del ganador (Copa América). Para el **comportamiento intrínseco** de los modelos —independiente de su puntería— empleamos métricas agnósticas de diversidad y estabilidad: Self-BLEU y distinct-2 (Li et al., 2016; Zhu et al., 2018), Vendi Score (Friedman and Dieng, 2023), entropía categórica y deriva temporal intra-persona, esta última medida con entrevistas paramétricas a los agentes en distintos puntos de la simulación (*Checkpoints Interview*). La capa de telemetría complementa ambas familias registrando el consumo de tokens —nuestra medida de costo de cómputo— y la adherencia al formato de salida (JSON).

4. Evaluación

4.1. Baseline: modelos aislados (Single-Agent)

Como línea de base ejecutamos cada modelo en aislamiento —toda la población sobre un mismo LLM— y sometimos el sistema a una batería de regímenes de estrés. Salvo indicación contraria, usamos Llama-3.3-70B como modelo ancla por ser el de mayor precisión en el caso cuantitativo.

4.1.1. Escalamiento topológico (rondas y densidad)

Variamos la profundidad del debate (número de rondas R) y la densidad de conexión del grafo de agentes (D). El efecto resultó opuesto según la naturaleza del caso (Tabla 2). En un entorno cuantitativo y cerrado (IPC), más deliberación mejora la inferencia: escalar a $R = 80$, $D = 2$ redujo el MAE a un óptimo de 1.84 %. En cambio, en un entorno abierto y polarizado (balotaje de Bolivia), el mismo escalamiento retroalimenta las asunciones del modelo y forma una cámara de eco (*herd behavior*): el error crece de 7.60 a 10.0 puntos de voto al pasar de 10 a 40 rondas.

4.1.2. Sesgos por arquitectura

Fijada una configuración de control ($R = 40$, $D = 2$), comparamos los tres modelos en el caso cuantitativo. La precisión ordena los modelos por

Entorno	R/D	MAE
IPC (cerrado)	10/2	3.12 %
IPC (cerrado)	40/1	2.45 %
IPC (cerrado)	40/2	2.31 %
IPC (cerrado)	80/2	1.84 %
Bolivia (abierto)	10/2	7.60
Bolivia (abierto)	40/2	10.0

Tabla 2: Escalamiento topológico con Llama-3.3-70B. Más rondas mejoran el caso cuantitativo cerrado (IPC, MAE en %) pero desencadenan *herd behavior* en el abierto (Bolivia, MAE en puntos de voto).

tamaño: Llama-3.3-70B obtiene el menor error (MAE 2.31 %), seguido de Gemma-3-27B (2.67 %) y Qwen3-8B (3.45 %). En su mejor configuración ($R = 80$, $D = 2$), Llama es además estable entre réplicas (MAE medio 1.85 %, $\sigma = 0.05$). Sin embargo, en escenarios sociales abiertos cada arquitectura exhibe una patología distinta: Llama tiende a la confirmación recursiva (burbuja epistemológica); Gemma muestra una impermeabilidad factual —mantuvo su voto pese a las estadísticas en contra en el caso deportivo, por el peso de su pre-entrenamiento—; y Qwen cae en una pasividad neutral, aunque es el más permeable a inyecciones de datos. Estas asimetrías motivan directamente el diseño multi-modelo (§4.2).

4.1.3. Deduplicación de nodos: costo y precisión

Durante la construcción del grafo detectamos una proliferación de nodos redundantes o casi idénticos, que aumentan el costo y el tiempo de cómputo. Añadimos un paso que verifica la similitud semántica antes de instanciar un nodo y descarta los nodos sin conectividad. En el caso IPC, esta optimización mejoró la precisión respecto de la ingesta manual sin deduplicación (MAE de 2.31 % a 1.475 %, la mejor marca del proyecto) además de reducir el número de nodos y, con ello, el costo. Al tratarse de una única prueba no podemos afirmar que la deduplicación mejore el pronóstico en general; pero en este caso redujo simultáneamente el cómputo y el error.

4.1.4. Permeabilidad e ingesta autónoma (Deep Search)

Evaluamos dotar al sistema de recolección de contexto totalmente autónoma (*Deep Search*) con cortes temporales estrictos. Lejos de mejorar, la precisión se degradó: en ausencia de anclas documentales estructuradas, la atención de los agentes

se dispersa y las proyecciones pierden consistencia. La ingesta curada del corpus semilla resultó preferible a la recolección autónoma.

4.1.5. Sensibilidad a la ventana temporal ($\Delta 1$ – $\Delta 4$)

Desplazando la ventana temporal de los datos semilla medimos la degradación del pronóstico en el caso IPC, con un patrón no lineal. A corto plazo ($\Delta 1$) el sistema es muy preciso (error de unos 0.1 puntos porcentuales), anclado en valores nominales presentes en el corpus. El mayor fallo ocurre a medio-corto plazo ($\Delta 2$): sin señales sobre *shocks* transitorios futuros, el modelo extrapola linealmente la tendencia inicial y subestima los rebotes macroeconómicos. A medio plazo ($\Delta 3$) la precisión se recupera para la tendencia de fondo. El motor es, entonces, robusto para la dirección dominante pero ciego a las fluctuaciones transitorias si la ventana no se actualiza.

4.1.6. Robustez ante ruido (inyecciones exógenas)

Inyectamos ruido deliberado en el entorno (p. ej. especulación cambiaria) y variamos su momento de entrada. Bajo alta profundidad ($R = 80$, $D = 2$), el modelo asimiló la especulación social contenida en el ruido y, paradójicamente, ancló un escenario recesivo con gran precisión (MAE de 0.9875 % en esa variante). El momento resultó crítico: datos correctos inyectados a mitad del debate suelen ser ignorados por arquitecturas con fuerte sesgo de pre-entrenamiento (Gemma), lo que confirma que la asimilación depende del balance entre el ruido externo y el arraigo de las creencias ya formadas.

4.1.7. Diversidad léxica y estabilidad (evaluación intrínseca)

Con independencia de la puntería predictiva, medimos el comportamiento generativo intrínseco de cada modelo con métricas agnósticas, sobre el caso más abierto (Bolivia) y con control de varianza (tres corridas por modelo con *equal-N*). Qwen3 no pudo incluirse por falta de acceso al modelo, de modo que la comparación es entre Gemma y Llama (Tabla 3).

Surgen tres asimetrías robustas, con rangos no solapados entre modelos. **Proactividad:** Llama es marcadamente reactivo —57 comentarios por cada 10 publicaciones originales—, mientras que Gemma es proactivo (18 publicaciones, 16 comentarios). **Diversidad léxica:** los posts de Gemma son mucho más variados (distinct-2 0.87 frente a 0.33;

Modelo	distinct-2↑	Self-BLEU↓	Deriva↑
Gemma-3-27B	0.87	0.11	0.41
Llama-3.3-70B	0.33	0.73	0.09

Tabla 3: Evaluación intrínseca de la salida (Caso Bolivia; *variance-checked*, 3 corridas/modelo, *equal-N*). Gemma produce texto más diverso y sus personas derivan más en el tiempo; Llama es más repetitivo y estático. Qwen3 no pudo evaluarse. Deriva: distancia *embedding* intra-persona inicio-fin (↑ = más deriva).

Self-BLEU 0.11 frente a 0.73), en tanto que Llama recicla estructuras. **Deriva temporal:** las personas de Gemma evolucionan a lo largo de la simulación (distancia *embedding* inicio-fin de 0.41), mientras que las de Llama permanecen estáticas (0.09).

Es notable que estas asimetrías no se explican por las personas iniciales: las de Llama son incluso algo más diversas al crearse (Vendi 9.2 frente a 8.4), y aun así sus posts convergen y se repiten. La menor diversidad y la estabilidad de Llama son, por tanto, un fenómeno de generación y no una consecuencia de personas homogéneas.

4.2. Multi-modelo: red heterogénea

Motivados por las asimetrías del baseline, poblamos una misma simulación con los tres modelos y replicamos los mismos regímenes de estrés. Nuestra hipótesis era que la fricción entre arquitecturas divergentes funcionaría como auto-regulación y reduciría el sesgo.

4.2.1. Escalamiento de rondas y colapso semántico

En el baseline, escalar las rondas con un solo modelo (Llama) inflaba la cámara de eco hasta un MAE de 10.0 en el balotaje de Bolivia. Al replicar la prueba con la red heterogénea y sin estímulos externos, la hipótesis de auto-regulación se refutó de forma contundente: en lugar de corregir hacia la verdad, el sistema sufrió un **colapso semántico** (*model collapse*). Forzados a dialogar sin nueva entropía, los agentes cayeron en un *deadlock* dialéctico —la hiper-reactividad de Llama frente a la proactividad de Gemma, moduladas por sus esquemas de alineación— y el foro se llenó de cortesía vacía (p. ej. “*I completely agree with the importance of considering the candidates’ policies...*”), sin que ningún modelo tomara postura.

El efecto es más severo que una simple pérdida de precisión: el 100 % de los agentes evadió emitir un voto, de modo que el evaluador no pudo ex-

Arquitectura	Predicción	MAE
Baseline (Llama), R10	Quiroga	7.687
Baseline (Llama), R40	Quiroga	10.000
Multi-modelo, R10	Sin predicción	66.667*
Multi-modelo, R40	Sin predicción	66.667*

Tabla 4: Balotaje de Bolivia sin inyecciones externas. La red heterogénea colapsa en abstención total: no emite un pronóstico válido. *Valor mecánico de una predicción nula (100 % “otros”), marcado como inválido en el informe fuente; no es comparable con los MAE del baseline.

traer ningún pronóstico válido. La métrica de error resultante (66.667) no es, por tanto, un MAE de pronóstico comparable con los del baseline, sino el valor mecánico que produce el evaluador ante una predicción nula —el 100 % de la masa asignada a la categoría “otros”— y la registramos como inválida (Tabla 4). El hallazgo cualitativo es que, en cautiverio y sin entropía externa, la red heterogénea no colapsa hacia el error sino hacia la *ausencia de predicción*.

4.2.2. Respuesta a la inyección de evidencia (variación de momento)

En el caso deportivo, la evaluación en aislamiento mostró un anclaje fuerte en el favorito (Argentina), resistente a la evidencia contraria. Para medir la respuesta a la evidencia exógena, ejecutamos una matriz de inyecciones a mitad del debate variando la fuerza y la dirección de la información. El ganador pronosticado siguió de cerca al documento inyectado: sin inyección quedaba indefinido (confianza 0.30); una señal fuerte a favor de Argentina lo consolidaba en ese resultado (0.90); una contra-señal a favor de Colombia hacía virar la predicción a Colombia (0.50), con uso explícito del documento; y el ruido temático fue mayormente ignorado. La evidencia inyectada dirige, por tanto, el pronóstico de forma efectiva, incluso en contra del favorito. Ahora bien, como Argentina resultó campeón, la contra-señal empujó al sistema hacia la predicción incorrecta: la maleabilidad no es veracidad.

4.2.3. Shock de ruido tardío (entropía exógena)

Sabiendo que la red colapsaba en neutralidad, inyectamos una encuesta falsa tardía a mitad del debate inactivo. El shock de entropía desestabilizó el estado de cortesía: Qwen, con la permeabilidad que ya mostraba en el baseline, absorbió el estímulo de inmediato, lo tradujo en retórica agresiva

e impulsó la polarización del foro, rescatando al sistema del colapso. Los LLM heterogéneos requieren señales externas continuas para sostener una deliberación sana.

4.2.4. Superación de la degradación temporal

En el baseline, alterar de forma estática el período de los datos semilla producía la curva de degradación temporal (fallo en $\Delta 2$ por extrapolación lineal). En la red multi-modelo abandonamos el corte estático y alimentamos a los agentes con flujos iterativos que simulan el paso del tiempo. El ecosistema heterogéneo —sometido a fricción dialéctica constante— procesó las actualizaciones sin caer en la extrapolación lineal ciega del modelo aislado: la diversidad arquitectónica actuó como amortiguador predictivo, estabilizando la inferencia a corto y medio plazo mientras el flujo de inyección no se interrumpiera.

5. Conclusiones

El contraste entre el *baseline* aislado y la red heterogénea nos permite volver sobre las dos hipótesis que motivaron este trabajo —que la heterogeneidad de modelos reduciría el sesgo y el costo— y matizarlas a la luz de la evidencia.

Para *forecasting* puro, la heterogeneidad no compensa. Un modelo aislado y bien calibrado no solo es más preciso (MAE de 1.84 % en IPC), sino también más barato: la red multi-modelo consume más de 230.000 *tokens* por debate y, sin estímulos externos, colapsa en abstención total, sin emitir un pronóstico utilizable (§4.2). Nuestra hipótesis de reducción de costos vía heterogeneidad no se sostiene para la tarea predictiva. La reducción de costo efectiva provino, en cambio, de una optimización ortogonal —la deduplicación semántica del grafo—, que en el único caso probado bajó el cómputo y mejoró la precisión a la vez.

La diversidad de modelos no se auto-regula, pero es permeable a la intervención. La hipótesis de que la fricción entre arquitecturas corregiría el sesgo de forma espontánea se refutó: en circuito cerrado, la red no converge a la verdad sino a un *deadlock* de cortesía. Lo que sí opera es su sensibilidad a la evidencia exógena: una inyección dirigida basta para desbloquear la deliberación estancada —el *shock* de una encuesta tardía rescató a la red del colapso (§4.2)— y para reorientar un pronóstico anclado, incluso en contra del favorito (§4.2). Ahora bien, permeabilidad no es acierto: en el caso

deportivo esa misma reorientación empujó la predicción hacia Colombia, que resultó perdedora. La heterogeneidad, entonces, aporta maleabilidad, no veracidad.

La precisión predictiva no requiere diversidad generativa. Un hallazgo transversal es que el mejor pronosticador (Llama) es, a la vez, el modelo intrínsecamente menos diverso y más estable en el tiempo, mientras que el más diverso (Gemma) es también el más volátil, con personas que derivan más a lo largo de la simulación (§4.1). Puntería y riqueza generativa son ejes independientes, y optimizar uno no implica el otro.

El valor de la red heterogénea es como laboratorio socio-técnico. MiroFish multi-modelo rinde no como pronosticador sino como entorno para estudiar dinámicas sociales bajo inyecciones paramétricas: es el único de nuestros montajes donde una señal exógena desencadena dinámicas colectivas —polarización del foro, absorción de (des)información y ruptura de un consenso estancado (§4.2)—. Ese, y no el *forecasting*, es a nuestro juicio el uso donde la heterogeneidad de modelos aporta valor genuino.

Limitaciones

Este trabajo tiene un alcance exploratorio y sus conclusiones deben leerse con varias salvedades.

Cobertura muestral. El *benchmark* usa un único evento por temática (económico, político y deportivo). Esto permite abarcar dominios diversos, pero impide afirmaciones estadísticamente concluyentes sobre las fortalezas o debilidades del sistema en cada uno; distinguir un efecto de dominio del ruido de un caso particular requeriría varios eventos por temática.

Control de varianza parcial. Solo algunas mediciones se repitieron con réplicas y control de varianza (la precisión del IPC y el análisis intrínseco de diversidad y deriva). Otros resultados —el escalamiento topológico, la inyección de ruido y el colapso multi-modelo— provienen de corridas únicas, por lo que sus valores puntuales deben tomarse como indicativos y no como estimaciones robustas.

Cobertura de modelos. La comparación intrínseca se realizó entre Gemma-3 y Llama-3.3; Qwen3 no pudo incluirse por falta de acceso al modelo durante esa fase. Además, evaluamos una

única terna de modelos en un rango de tamaño acotado (8B–70B) y una sola configuración de mezcla. No podemos garantizar que las conclusiones sean agnósticas al tamaño ni a la elección concreta de modelos; explorar otras combinaciones y escalas mayores es trabajo pendiente.

Métricas de evaluación. El MAE de participación electoral se calcula a partir de la extracción, mediante expresiones regulares, de porcentajes en el informe generado; una predicción mal formada puede no ser detectada. En particular, el valor asociado al colapso semántico multi-modelo no es un error de pronóstico comparable, sino el resultado mecánico de una predicción nula, y así lo señalamos. El MAE se expresa además en unidades distintas según el caso (puntos porcentuales de inflación frente a puntos de voto), por lo que los valores no son comparables entre casos.

Reproducibilidad. Las simulaciones dependen de modelos servidos por terceros y el costo se aproxima por el conteo de tokens de la telemetría, no por un perfilado exhaustivo ni por su traducción a un costo monetario. La deduplicación de nodos, por su parte, se validó en un único caso, sin cuantificar de forma independiente la reducción exacta del tamaño del grafo.

References

- Dan Friedman and Adji Bousso Dieng. 2023. The vendi score: A diversity evaluation metric for machine learning. *Transactions on Machine Learning Research*.
- Gemma Team, Google DeepMind. 2025. Gemma 3 model card. https://ai.google.dev/gemma/docs/core/model_card_3. Knowledge cutoff: August 2024.
- Jiwei Li, Michel Galley, Chris Brockett, Jianfeng Gao, and Bill Dolan. 2016. A diversity-promoting objective function for neural conversation models. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*.
- Llama Team, Meta AI. 2024. Llama-3.3-70B-Instruct model card. <https://huggingface.co/meta-llama/Llama-3.3-70B-Instruct>. Knowledge cutoff: December 2023.
- MiroFish Contributors. 2025. MiroFish: A simple and universal swarm intelligence engine. <https://github.com/666ghj/MiroFish>. Repositorio GitHub. Verificar autor y año.
- Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, et al. 2022. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Joon Sung Park, Joseph C. O’Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. 2023. Generative agents: Interactive simulators of human behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST)*.
- Qwen Team. 2025. Qwen3 technical report. <https://arxiv.org/abs/2505.09388>.
- Ilia Shumailov, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. 2024. AI models collapse when trained on recursively generated data. *Nature*, 631. Verificar páginas.
- Ziyi Yang, Zaibin Zhang, Zirui Zheng, Yuxian Jiang, Ziyue Gan, et al. 2024. OASIS: Open agent social interaction simulations with one million agents. *arXiv preprint arXiv:2411.11581*.
- Yaoming Zhu, Sidi Lu, Lei Zheng, Jiaxian Guo, Weinan Zhang, Jun Wang, and Yong Yu. 2018. Texus: A benchmarking platform for text generation models. In *Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval*.