



Poblaciones heterogéneas de LLMs para pronóstico social

Un estudio empírico sobre el simulador *MiroFish*

Andrés Bravo Joaquín Cadeiras Bruno De Cruz Lucas Ercolano Eliana Ostrovsky


Universidad de San Andrés — Procesamiento del Lenguaje Natural



¿Puede la Inteligencia Artificial simular a una sociedad entera?

MiroFish es un motor de pronóstico *ya existente* basado en *simulación social generativa*: instancia una población de agentes LLM en un foro virtual (clon de Twitter/Reddit), les inyecta noticias reales vía un grafo de conocimiento en Neo4j, los hace deliberar y destila una predicción a partir del consenso emergente. El sistema corre *todos* los agentes sobre un mismo LLM: una población homogénea hereda las patologías de ese modelo —cámaras de eco, rigidez, baja diversidad léxica— y encarece el cómputo si el modelo es grande.

Partimos de MiroFish y estudiamos una modificación concreta: poblar la simulación con modelos *heterogéneos* (Llama-3.3-70B, Gemma-3-27B, Qwen3-8B), bajo la hipótesis de que la fricción entre arquitecturas divergentes reduciría el sesgo y el costo del pronóstico.



La tubería de MiroFish; en color, las dos etapas donde intervenimos (nuestros aportes).

Un benchmark de tres casos


Como no existía un punto de comparación para el sistema, construimos uno propio: tres eventos de dominios distintos, todos *posteriores* al corte documental, con el *ground truth* aislado del *input* y corridas herméticas (sin acceso a Internet).

Dominio	Caso real	Perfil	Métrica
Económico	IPC Argentina	Cuantitativo	MAE (%)
Político	Elecciones	Abierto / polarizado	MAE (voto)
Deportivo	Copa América	Sanidad corto plazo	Acierto

Sobre esa base, nuestros aportes técnicos son: (i) ruteo heterogéneo de modelos por agente con telemetría de tokens, latencia y costo; (ii) deduplicación semántica del grafo (Neo4j + *embeddings*); y (iii) un análisis empírico de población homogénea frente a heterogénea.

La paradoja del escalamiento

Con un modelo aislado, dar *más rondas* de debate no tiene un efecto universal: ayuda al caso cuantitativo cerrado (IPC) pero no corrige el caso abierto y polarizado (Elecciones).




Escalas distintas por dominio; los MAE no son comparables entre sí.

A igual configuración ($R=40$, $D=2$), la precisión ordena por tamaño: Llama (2.31%) < Gemma (2.67%) < Qwen (3.45%). Cada arquitectura, sin embargo, muestra una patología propia: Llama, confirmación recursiva; Gemma, impermeabilidad factual; Qwen, pasividad neutral pero más permeable a inyecciones.

Deduplicación semántica del grafo


Antes de debatir, los agentes ingieren noticias en un grafo de conocimiento. Nuestro algoritmo fusiona nodos redundantes comparando *embeddings* (similitud coseno > 0.85).



Es una optimización *ortogonal* que reduce la carga atencional del modelo. En una corrida de IPC bajó el MAE de 2.31% a **1.475%**: una señal favorable de *una sola corrida*, no una mejora general demostrada.

Eco vs. deriva: comportamiento intrínseco

Medimos el comportamiento generativo de los modelos aislados con métricas agnósticas, independientes de la puntería (caso Elecciones, *variance-checked*; Qwen quedó fuera por falta de acceso).



Llama (reactivo) recicla estructuras y forma una cámara de eco estática (Self-BLEU 0.73, deriva 0.09). Gemma (proactivo) es léxicamente rico y sus personas evolucionan (deriva 0.41), aunque desarrolla “terquedad” factual.

Hallazgo transversal: el mejor pronosticador (Llama) es a la vez el *menos* diverso y más estable. Puntería y riqueza generativa son ejes independientes.

La red heterogénea colapsa

Poblamos una misma simulación con los tres modelos, esperando que la fricción entre arquitecturas se auto-regulara. La hipótesis se refutó: en circuito cerrado y sin estímulos externos, el caso de las Elecciones sufrió un *colapso semántico*.

100 %
de los agentes se abstuvo de votar

Los agentes cayeron en bucles de cortesía vacía (“*I completely agree...*”) sin tomar postura: la red no colapsa hacia el error sino hacia la *ausencia de predicción*.

Escalar tampoco ayudó: en IPC trimodelo, el costo se disparó de 50 231 tokens ($R=10$) a 5 546 655 ($R=80$) —dos órdenes de magnitud— mientras la calidad caía de 3/5 a 1/5.

Permeabilidad: shocks de entropía

La diversidad de modelos no se auto-regula, pero sí es *permeable* a la intervención externa.

- **Contraseñañ (baseline aislado).** En la matriz de inyecciones S3, una contraseña cambió la dirección en los tres dominios; Gemma, rígido en fútbol, sí cedió en Elecciones e IPC. La permeabilidad depende del modelo y del caso.
- **Shock tardío (red multi-modelo).** Una *encuesta falsa* inyectada en el debate estancado rescató a la red: Qwen absorbió el estímulo, lo volvió retórica agresiva y relanzó la polarización.

En ambos casos la señal reorienta la deliberación, pero *permeabilidad no es veracidad*.

Conclusión: un laboratorio socio-técnico

Arquitectura	Costo	Puntería	Maleabilidad
Aislado (Llama)	Bajo	Alta	Baja (eco)
Red (sin shocks)	Extremo	Nula (<i>deadlock</i>)	Nula
Red + entropía	Alto	Media	Alta

Para el *forecasting* puro, la heterogeneidad no compensa: un modelo aislado y calibrado es más preciso (MAE 1.84% en IPC) y más barato, y el ahorro real vino de la deduplicación, no de la red. Su valor genuino es otro: como *simulador poblacional* auditable, es el único montaje donde una señal exógena desencadena polarización, absorción de (des)información y ruptura de consensos.